
Traveling Salesman Problem with Multiple Drones (TSP-mD): Formulaci3n, Complejidad, Aplicaciones y Estado del Arte

Alfonso Gysling, Carlos Castro, Benjamin Zuñiga — Optimizaci3n — Secci3n 202610.7924

Universidad Andr3s Bello, Facultad de Ingenier3a — Santiago, Chile

Per3odo 2026



Universidad
Andr3s Bello®

Resumen

El Traveling Salesman Problem with Multiple Drones (TSP-mD) es una variante del cl3sico Problema del Viajante de Comercio en la que un cam3n de reparto colabora con m drones homog3neos para atender un conjunto de clientes minimizando el tiempo total de finalizaci3n. El problema pertenece a la clase NP-dif3cil y captura la esencia de los sistemas modernos de entrega de 3ltima milla, donde los veh3culos no tripulados (UAV) complementan al veh3culo terrestre con mayor velocidad de vuelo pero capacidad de carga y autonom3a limitadas. En este trabajo se presenta la formulaci3n matem3tica MILP est3ndar del TSP-mD, se analiza su complejidad computacional, se describen aplicaciones reales en log3stica, humanitarismo y agricultura de precisi3n, y se revisa cr3ticamente el estado del arte de los m3todos de resoluci3n —desde enfoques exactos hasta metaheur3sticas y aprendizaje profundo—. Se posiciona LKH-3 como marco de soluci3n de referencia para esta variante, describiendo la transformaci3n a TSP restringido que aplica Helsgaun. Finalmente, se identifican brechas abiertas y tendencias de investigaci3n reciente.

Palabras clave: TSP-mD, drones de reparto, entrega de 3ltima milla, optimizaci3n combinatorial, LKH-3, MILP, metaheur3sticas.

I. INTRODUCCIÓN

La entrega de última milla —el tramo final entre un centro de distribución y el cliente final— representa hasta el 28 % del costo logístico total en comercio electrónico [1]. La incorporación de vehículos aéreos no tripulados (UAV, drones) como complemento a camiones de reparto ha emergido como una estrategia prometedora para reducir tiempos de entrega y costos operativos [2].

El Traveling Salesman Problem with Drone (TSP-D), introducido por Murray y Chu [3] como Flying Sidekick TSP (FSTSP), modela la colaboración de un camión y un único drone. La extensión natural al caso con múltiples drones (TSP-mD) permite despachar m drones simultáneamente desde el camión, incrementando significativamente la cobertura por unidad de tiempo [4].

LKH-3, el solver heurístico desarrollado por Keld Helsgaun [5], incluye soporte nativo para el TSP-mD en su repositorio de benchmarks. Su estrategia general consiste en transformar variantes complejas en instancias de TSP restringido y aplicar el método k-opt del Lin-Kernighan, logrando resultados competitivos con tiempos de cómputo razonables para instancias de tamaño práctico [5].

Este paper tiene por objetivo: (i) formalizar matemáticamente el TSP-mD, (ii) analizar su complejidad, (iii) exponer aplicaciones reales documentadas, (iv) revisar críticamente el estado del arte de métodos de resolución, (v) describir el rol específico de LKH-3, y (vi) identificar brechas y líneas de investigación abiertas.

II. DEFINICIÓN FORMAL DEL PROBLEMA

El TSP-mD se define sobre un grafo dirigido completo $G = (V, E)$, donde $V = \{0, 1, \dots, n\}$ es el conjunto de nodos: el nodo 0 es el depósito y los nodos 1 a n son los clientes. El arco $(i, j) \in E$ tiene asociado un tiempo de viaje en camión τ_{ij}^T y un tiempo de vuelo en drone τ_{ij}^D .

El sistema cuenta con un camión y m drones homogéneos. El camión recorre una ruta que comienza y termina en el depósito visitando un subconjunto de nodos directamente. Los drones son lanzados desde nodos de la ruta del camión (nodos de lanzamiento), visitan exactamente un cliente cada uno (salvo generalizaciones multi-drop) y regresan a un nodo de recuperación posterior en la misma ruta del camión [4][6].

Las restricciones clave son:

1. Todo cliente debe ser atendido exactamente una vez, ya sea por el camión o por algún drone.
2. Un drone lanzado en el nodo i y recuperado en el nodo k debe regresar antes de que el camión parta de k (sincronización).
3. La autonomía del drone limita la distancia total de vuelo entre lanzamiento y recuperación.
4. El camión no puede tener más de m drones en vuelo simultáneamente.

La función objetivo es minimizar el makespan $C_{\max}$, definido como el tiempo en que el camión y todos los

drones regresan al depósito habiendo completado todas las entregas [4][6].

III. FORMULACIÓN MATEMÁTICA

A. Variables de decisión

Variables binarias del camión: $x_{ij} \in \{0,1\}$ indica si el camión recorre el arco (i,j) .

Variables de asignación drone: $y_{ij}^d \in \{0,1\}$ indica si el drone d atiende al cliente j lanzado desde el nodo i .

Variables de recuperación: $z_{ijk}^d \in \{0,1\}$ indica si el drone d , lanzado en i hacia j , es recuperado en k .

Variables continuas: $t_i^T \geq 0$ tiempo de llegada del camión al nodo i ; $t_j^{D,d} \geq 0$ tiempo de llegada del drone d al cliente j .

B. Formulación MILP (adaptada de Dell'Amico et al. [6])

La formulación compacta se estructura como:

min $C_{\max}$

s.a.

- (1) $C_{\max} \geq t_i^T \quad \forall i \in V$
- (2) $C_{\max} \geq t_j^{D,d} + \tau_{kd}^D \quad \forall d, \forall (i,j,k) : z_{ijk}^d = 1$
- (3) $\sum_j x_{ij} = 1 \quad \forall i \in V$ (flujo saliente camión)
- (4) $\sum_i x_{ij} = 1 \quad \forall j \in V$ (flujo entrante camión)
- (5) $\sum_d \sum_i y_{ij}^d + \sum_k x_{kj} = 1 \quad \forall j \in V \setminus \{0\}$ (cobertura total)
- (6) $t_j^T \geq t_i^T + \tau_{ij}^T \cdot x_{ij} - M(1 - x_{ij}) \quad \forall (i,j)$
- (7) $t_j^{D,d} \geq t_i^T + \tau_{ij}^D \cdot y_{ij}^d - M(1 - y_{ij}^d)$
- (8) $t_k^T \geq t_j^{D,d} + \tau_{jk}^D \cdot z_{ijk}^d$ (sincronización recuperación)
- (9) $\sum_d \sum_j y_{ij}^d \leq m \cdot \sum_k x_{ik} \quad \forall i$ (capacidad de drones)
- (10) $\tau_{ij}^D + \tau_{jk}^D \leq E_{\max} \cdot z_{ijk}^d$ (autonomía drone)

Donde $E_{\max}$ es la autonomía máxima del drone y M es una constante suficientemente grande. Las restricciones (3)-(4) garantizan la validez de la ruta del camión; (5) asegura cobertura completa; (6)-(8) modelan la propagación temporal y la sincronización; (9) respeta la flota de drones; (10) impone la restricción de autonomía [4][6].

IV. COMPLEJIDAD COMPUTACIONAL

El TSP-mD pertenece a la clase NP-difícil. Su dificultad se establece por reducción polinomial desde el TSP clásico: cuando $m = 0$ (sin drones), el TSP-mD se reduce exactamente al TSP simétrico, problema NP-completo en su versión de decisión [7].

La presencia de múltiples drones introduce dos fuentes adicionales de complejidad: (i) la asignación combinatorial de clientes a drones en cada posible tripleta (lanzamiento,

cliente, recuperación), y (ii) la sincronización temporal entre el camión y cada drone activo. Agatz et al. [8] demuestran que incluso la versión con un solo drone (TSP-D) es NP-difícil. Con m drones la dificultad es estrictamente mayor dado el espacio de estados exponencial en m .

En la práctica, los métodos exactos (MILP y branch-and-cut) resuelven de manera óptima instancias de hasta ~30-40 clientes en tiempos razonables [6]. Para instancias medianas (50-200 clientes) se requieren heurísticas; para instancias grandes (>200 clientes) solo los enfoques de aprendizaje profundo o metaheurísticas avanzadas producen soluciones de calidad en tiempo útil [9].

La complejidad parametrizada respecto al número de drones m también es relevante: aumentar m incrementa exponencialmente las posibles asignaciones de triplas (i, j, k) por drone, lo que convierte la resolución exacta en intratable para $m > 4-5$ incluso con n moderado.

V. RELEVANCIA Y APLICACIONES

A. Logística de última milla en e-commerce

Amazon, DHL y UPS han pilotado sistemas camión-drone en zonas suburbanas y rurales. Arishi et al. [10] demuestran mediante simulaciones con datos reales que la incorporación de múltiples drones por camión puede reducir el tiempo de entrega hasta un 40 % respecto a rutas puramente terrestres, especialmente cuando los clientes se distribuyen en zonas con baja densidad y calles de difícil acceso.

B. Logística humanitaria y asistencia en desastres

En contextos de desastre natural (inundaciones, terremotos), la infraestructura vial puede colapsar. El esquema camión-multidrone permite llevar suministros médicos a puntos inaccesibles por carretera. Shi et al. [11] modelan la colaboración helicóptero-camión-drone para distribución de emergencia post-desastre, evidenciando reducción de tiempos de respuesta de hasta un 55 %.

C. Agricultura de precisión y monitoreo territorial

Drones lanzados desde vehículos terrestres recorren cultivos para monitoreo de plagas, riego de precisión o entrega de insumos agroquímicos en puntos georreferenciados. La variante TSP-mD captura directamente la planificación de rutas del vehículo terrestre y las misiones de los UAV, evitando el retorno al depósito entre drones [12].

D. Entrega en zonas urbanas densas

En ciudades, los drones eluden el tráfico terrestre. Estudios con datos de la red vial de Beijing muestran que modelos de tipo TSP-mD reducen el makespan entre un 20-30 % frente a rutas puramente terrestres en escenarios de alta congestión [13].

VI. ESTADO DEL ARTE

A. Métodos exactos

El primer enfoque exacto relevante para el TSP-D fue propuesto por Agatz et al. [8] mediante programación dinámica, resoluble de forma óptima hasta ~12 nodos. Dell'Amico et al. [6] presentaron en 2021 la primera

formulación MILP compacta para el TSP-MD (un camión, m drones) junto con familias de desigualdades válidas y un algoritmo de branch-and-cut, alcanzando instancias de hasta 39 clientes en tiempos prácticos. Su formulación es hoy la referencia canónica del problema.

La descomposición branch-and-price es otro enfoque exacto prometedor: genera columnas correspondientes a operaciones de drone (tripletas $i-j-k$) de manera dinámica, permitiendo manejar el espacio de variables sin enumerar todas las tripletas a priori [9].

B. Heurísticas constructivas y búsqueda local

Ha et al. [4] propusieron el primer método heurístico para el TSP-mD basado en GRASP (Greedy Randomized Adaptive Search Procedure), que construye soluciones iniciales aleatorizadas y aplica búsqueda local. Sus experimentos muestran que aumentar m mejora el makespan con retornos decrecientes más allá de $m = 3-4$.

El Adaptive Large Neighborhood Search (ALNS) de Nguyen et al. [14] aplica operadores de destrucción/replicación sobre la solución actual, demostrando superioridad frente al GRASP en instancias medianas. El esquema "order-first, split-second" propuesto por Boysen et al. [15] resuelve una secuencia de clientes óptima como TSP clásico y luego asigna subconjuntos a drones mediante programación dinámica en tiempo polinomial.

C. Metaheurísticas

Los algoritmos genéticos (GA) con codificación especializada para rutas camión-drone han sido ampliamente estudiados. Zhou et al. [16] proponen un GA mejorado con operadores de cruce adaptados al TSP-mD, reportando soluciones de alta calidad en instancias de hasta 100 clientes en tiempos de minutos. La hibridación con búsqueda tabú y recocido simulado también ha sido explorada [17].

Los algoritmos basados en colonia de hormigas (ACO) han sido adaptados para el TSP-D, aunque con menor presencia en la literatura específica del TSP-mD. Las colonias modelan feromona separada para arcos de camión y tripletas de drone.

D. Aprendizaje automático y deep learning

Chen et al. [18] aplican Q-learning para mejorar una metaheurística paralela de drones, logrando convergencia más rápida al combinar exploración basada en recompensas con búsqueda local. Las Graph Neural Networks (GNN) han emergido como enfoque de fin a fin para resolver instancias de TSP-mD de forma aproximada, aprendiendo políticas de asignación directamente desde instancias de entrenamiento [19].

Kool et al. y trabajos posteriores demuestran que los transformers de atención pueden resolver el TSP clásico a nivel competitivo con LKH; su extensión al TSP-mD es un área activa de investigación [9].

E. Marco unificado basado en LKH-3

Un desarrollo notable reciente es el framework unificado de Luo et al. [20], que usa LKH-3 como motor de búsqueda para tres variantes camión-drone (FSTSP,

TSP-mD, VRP-D). Este trabajo, validado en 2026, demuestra la flexibilidad de LKH-3 para abordar el TSP-mD sin necesidad de rediseñar el algoritmo base.

VII. ROL ESPECÍFICO DE LKH-3

A. Arquitectura general del solver

LKH-3 (Lin-Kernighan-Helsgaun versión 3) es una extensión del algoritmo LKH para resolver alrededor de 40 variantes de TSP y VRP [5]. Su estrategia central consiste en transformar cada variante en un TSP restringido equivalente, luego aplicar el método k-opt mejorado con estructuras de candidatos guiadas por la medida α (α -nearness), que estima la calidad de aristas mediante el árbol generador mínimo del grafo.

B. Transformación del TSP-mD

Para el TSP-mD, LKH-3 representa la ruta combinada (camión + operaciones de drones) como una secuencia de nodos extendida. Cada operación de drone ($i \rightarrow j \rightarrow k$) se codifica como un "nodo virtual" en la representación interna, permitiendo que los operadores k-opt actúen sobre la secuencia global sin distinguir entre movimientos del camión y del drone durante la búsqueda local [5][20].

Las restricciones de sincronización y autonomía se implementan mediante penalizaciones en la función de evaluación: soluciones que violan la autonomía o la precedencia de recuperación reciben un costo penalizado alto, guiando la búsqueda hacia soluciones factibles.

C. Resultados reportados

Helsgaun mantiene en su repositorio instancias de benchmark TSP-mD (directorio TSPMD.tgz) que sirven como referencia para comparar métodos. Los resultados del framework de Luo et al. [20], basado en LKH-3, muestran mejoras respecto a heurísticas específicas del dominio en instancias medianas, validando la generalidad del enfoque. La ventaja de LKH-3 es su robustez: dado que no asume estructura particular del grafo, funciona bien incluso con distribuciones asimétricas de clientes.

VIII. DISCUSIÓN Y TRABAJO FUTURO

A pesar del avance significativo en métodos de resolución, el TSP-mD presenta varias brechas relevantes:

Escalabilidad de métodos exactos. Las formulaciones MILP existentes no resuelven de forma óptima instancias con más de ~40 clientes en tiempos razonables. El desarrollo de técnicas de descomposición más finas (Benders, branch-and-price mejorado) sigue siendo un problema abierto [6].

Heterogeneidad de drones. La gran mayoría de los modelos asumen drones homogéneos. Flotas con drones de distinta autonomía, velocidad o capacidad de carga representan una generalización poco explorada de alta relevancia práctica.

Incertidumbre y robustez. Los modelos actuales son determinísticos. La incorporación de incertidumbre en tiempos de vuelo (viento, tráfico aéreo) y demandas

estocásticas abre líneas de investigación en optimización robusta y estocástica.

Integración con múltiples camiones. La extensión a m-camiones y k-drones por camión (mTSPD) escala la dificultad combinatoriamente. Trabajos recientes como el de Thomas et al. [21] abordan la planificación de drones en ruta (en-route operations), pero la optimización conjunta sigue siendo computacionalmente desafiante.

Aprendizaje profundo end-to-end. Las GNN y transformers muestran promesa para generar soluciones iniciales de calidad, pero su integración como componentes de soluciones híbridas con LKH-3 está en etapas tempranas [18][19].

Las tendencias más activas en literatura reciente (2022-2026) incluyen: (i) modelos que incorporan física del vuelo de drones (consumo energético dependiente del peso y del viento), (ii) optimización en entornos dinámicos con llegadas de pedidos en tiempo real, y (iii) consideraciones de sostenibilidad y emisiones de CO₂ en comparación con reparto exclusivo en camión.

IX. CONCLUSIÓN

El TSP-mD representa un problema de optimización combinatorial NP-difícil de creciente relevancia práctica, impulsado por la masificación de los UAV en logística de última milla. Su formulación MILP captura con precisión la sincronización entre camión y drones, aunque la resolución exacta escala mal con el tamaño de la instancia.

El estado del arte combina métodos exactos de referencia (branch-and-cut con formulación compacta) con heurísticas sofisticadas (GRASP, ALNS) y enfoques de aprendizaje automático emergentes. LKH-3 ocupa una posición privilegiada como solver heurístico de propósito general: su mecanismo de transformación a TSP restringido le permite abordar el TSP-mD sin rediseño específico, manteniendo la calidad y generalidad del motor k-opt subyacente.

Las brechas identificadas —escalabilidad exacta, heterogeneidad de flotas, robustez bajo incertidumbre e integración con deep learning— definen la agenda de investigación de los próximos años en este campo.

DECLARACIÓN DE USO DE IA

Para la redacción del presente trabajo se utilizó Claude (Anthropic) como herramienta de asistencia en la estructuración y redacción del texto en prosa académica, búsqueda y síntesis bibliográfica, y generación de esquemas iniciales de la formulación matemática. Todas las referencias citadas fueron verificadas por al menos un integrante del grupo. El análisis crítico, el posicionamiento de LKH-3 y la discusión de brechas son producto del trabajo intelectual del equipo.

REFERENCIAS

- [1] Statista Research Department, "Last-mile delivery costs as a share of total delivery cost worldwide," Statista, 2023.
- [2] G. Macrina, L. Di Puglia Pugliese, F. Guerriero, and G. Laporte, "Drone-aided routing: A literature review", "

- Transportation Research Part C: Emerging Technologies, vol. 120, p. 102762, 2020.
- [3] B. C. Murray and R. B. Chu, "The flying sidekick traveling salesman problem: Optimization of drone-assisted parcel delivery," *Transportation Research Part C*, vol. 54, pp. 86-109, 2015.
 - [4] Q. Ha, K. Deville, Q. D. Pham, and M. H. Ha, "Traveling salesman problem with multiple drones," in *Proc. 9th Int. Symp. Information and Communication Technology (SoICT)*, pp. 46-53, ACM, 2018.
 - [5] K. Helsgaun, "An extension of the Lin-Kernighan-Helsgaun TSP solver for constrained traveling salesman and vehicle routing problems," *Roskilde University Technical Report*, 2017.
 - [6] M. Dell'Amico, F. Monaci, C. Pagani, and D. Vigo, "Exact methods for the traveling salesman problem with multiple drones," *Transportation Research Part C: Emerging Technologies*, vol. 130, p. 103280, 2021.
 - [7] M. R. Garey and D. S. Johnson, *Computers and Intractability: A Guide to the Theory of NP-Completeness*. W. H. Freeman, 1979.
 - [8] N. Agatz, P. Bouman, and M. Schmidt, "Optimization approaches for the traveling salesman problem with drone," *Transportation Science*, vol. 52, no. 4, pp. 965-981, 2018.
 - [9] J. Pasha, Z. Elmi, S. Purkayastha et al., "The drone scheduling problem: A systematic state-of-the-art review," *IEEE Transactions on Intelligent Transportation Systems*, vol. 23, no. 9, pp. 14224-14247, 2022.
 - [10] A. Arishi, K. Krishnan, and M. Arishi, "Machine learning approach for truck-drones based last-mile delivery in the era of industry 4.0," *Engineering Applications of Artificial Intelligence*, vol. 116, p. 105439, 2022.
 - [11] Y. Shi, J. Yang, Q. Han, H. Song, and H. X. Guo, "Optimal decision-making of post-disaster emergency material scheduling based on helicopter-truck-drone collaboration," *Omega*, vol. 127, p. 103104, 2024.
 - [12] F. Verdouw, H. Sundmaeker, T. Tekinerdogan, D. Conzon, and T. Montanaro, "Architecture framework of IoT-based food and farm systems: A multiple case study," *Computers and Electronics in Agriculture*, vol. 165, p. 104939, 2019.
 - [13] W. He, G. Jin, Z. Huang, L. Yi, C. Lv, and F. Su, "Coordinated last-mile deliveries with trucks and drones: A comparative study," *Transportation Research Interdisciplinary Perspectives*, 2024.
 - [14] V. T. Nguyen, Q. D. Pham, and M. H. Ha, "An adaptive large neighborhood search for the traveling salesman problem with multiple drones," in *GECCO 2020 Companion Proc.*, 2020.
 - [15] N. Boysen, S. Schwerdfeger, and F. Weidinger, "Scheduling last-mile deliveries with truck-based autonomous robots," *European Journal of Operational Research*, vol. 271, no. 3, pp. 1085-1099, 2018.
 - [16] L. Zhou, F. Shi, and A. E. Smith, "Joint optimization of truck-drone routing for last-mile deliveries in urban areas," *Transportation Letters*, 2024.
 - [17] B. Madani and M. Ndiaye, "Hybrid truck-drone delivery systems: A systematic literature review," *IEEE Access*, vol. 10, pp. 92854-92872, 2022.
 - [18] P. Chen and Q. Wang, "Learning for multiple purposes: A Q-learning enhanced hybrid metaheuristic for parallel drone scheduling traveling salesman problem," *Computers and Industrial Engineering*, 2022.
 - [19] Z. Li, Z. Huang, and S. Gama, "Physics-aware truck and drone delivery planning using deep reinforcement learning," *arXiv preprint*, 2025.
 - [20] Z. Luo, J. Ma, and Q. Zhang, "A unified solution framework for truck-and-drone routing problems," *arXiv preprint arXiv:2602.20310*, 2026.
 - [21] T. Thomas, S. Srinivas, and C. Rajendran, "Collaborative truck multi-drone delivery system considering drone scheduling and en-route operations," *Annals of Operations Research*, vol. 339, pp. 693-739, 2023.
 - [22] K. Helsgaun, "An effective implementation of the Lin-Kernighan traveling salesman heuristic," *European Journal of Operational Research*, vol. 126, pp. 106-130, 2000.
 - [23] M. Kitjacharoenchai, B. C. Ventresca, M. Moshref-Javadi et al., "Multiple traveling salesman problem with drones: Mathematical model and heuristic approach," *Computers and Industrial Engineering*, vol. 129, pp. 14-30, 2019.
 - [24] D. Cicek, M. Simsek et al., "Resilient last-mile logistics in smart cities through multi-visit and time-dependent drone-truck collaboration," *Drones*, vol. 9, 2025.
 - [25] T. Bektas, "The multiple traveling salesman problem: An overview of formulations and solution procedures," *Omega*, vol. 34, no. 3, pp. 209-219, 2006.