

RESUMEN

El TSP-mD modela un **camión de reparto** que colabora con **m drones homogéneos** para atender a todos los clientes minimizando el makespan (tiempo total de finalización). El problema pertenece a la clase **NP-difícil** y es motor de los sistemas modernos de entrega de última milla. Se formaliza su formulación MILP, se analiza su complejidad, se documentan aplicaciones industriales reales, se revisa críticamente el estado del arte (exactos, heurísticos, metaheurísticas, deep learning) y se posiciona **LKH-3** como solver de referencia mediante su mecanismo de transformación a TSP restringido.

Palabras clave: TSP-mD · drones · última milla · optimización combinatorial · NP-difícil · LKH-3 · MILP · metaheurísticas

Definición del Problema




Fig. 1: Esquema TSP-mD — camión + 2 drones, depósito → clientes → depósito

Se define sobre un grafo dirigido completo $G = (V, E)$, con depósito en el nodo 0 y clientes 1...n. Cada arco (i, j) tiene tiempo de camión τ_{ij}^T y tiempo de vuelo τ_{ij}^D . El sistema opera con **1 camión** y **m drones homogéneos**.

Restricciones clave

- Cada cliente atendido **exactamente una vez** (camión o drone)
- Sincronización:** drone recuperado en k antes de que el camión parta de k
- Autonomía:** $\tau_{ij}^D + \tau_{jk}^D \leq E_{\max}$
- Máximo **m drones en vuelo simultáneo**

Objetivo: minimizar makespan $C_{\max}$ = tiempo en que camión y todos los drones regresan al depósito.

Formulación MILP

Variables de decisión

$x_{ij} \in \{0, 1\}$ El camión recorre el arco (i, j)

$y_{ij}^d \in \{0, 1\}$ Drone d atiende cliente j lanzado desde i

$z_{ijk}^d \in \{0, 1\}$ Drone d lanzado en i → j recuperado en k

$t_i^T \geq 0$ Tiempo llegada camión al nodo i

$t_{ij}^{D,d} \geq 0$ Tiempo llegada drone d al cliente j

min $C_{\max}$
sujeto a:

- $C_{\max} \geq t_i^T \quad \forall i \in V$
- $C_{\max} \geq t_{ij}^{D,d} + \tau_{kd}^D \quad \forall d, z_{ijk}^d = 1$
- $\sum_j x_{ij} = \sum_i x_{ji} \quad \forall i \in V \quad [flujo\ salida]$
- $\sum_i x_{ij} = 1 \quad \forall j \in V \quad [flujo\ entrada]$
- $\sum_d \sum_i y_{ij}^d + \sum_k x_{kj} = 1 \quad \forall j \quad [cobertura]$
- $t_j^T \geq t_i^T + \tau_{ij}^T - M(1 - x_{ij})$
- $t_{ij}^{D,d} \geq t_i^T + \tau_{ij}^D - M(1 - y_{ij}^d)$
- $t_k^T \geq t_{ij}^{D,d} + \tau_{jk}^D - M(1 - z_{ijk}^d) \quad [sinc.]$
- $\sum_j y_{ij}^d \leq m \quad \forall i \quad [cap.]$
- $t_{ij}^{D,d} + \tau_{jk}^D \leq E_{\max} \quad \forall i, j, k \quad [autonomia]$

Formulación compacta adaptada de Dell'Amico et al. [6], 2021. M es constante big-M. (3)–(4) validan la ruta; (5) garantiza cobertura total; (6)–(8) propagan tiempos y sincronizan; (9) respeta la flota; (10) limita autonomía.

Complejidad Computacional




Fig. 2: Jerarquía de reducción — $TSP \subseteq TSP-D \subseteq TSP-mD$

La NP-dificultad se establece por **reducción polinomial**: con m=0, el TSP-mD se reduce exactamente al TSP simétrico clásico. Agatz et al. [8] prueban la NP-dificultad del TSP-D; el caso múltiple es estrictamente más difícil.

Instancias tratables en la práctica

Rango n	Método viable	Tiempo aprox. segundos
≤ 12	Prog. dinámica exacta	
≤ 39	Branch-and-cut MILP	minutos
50–200	GRASP / ALNS / GA	seg.–min.
>200	Deep learning / LKH-3	min.–hora

Aumentar m genera espacio exponencial de tripletas (i,j,k) por drone, haciendo la resolución exacta intratable para **m > 4–5** incluso con n moderado.

Aplicaciones Reales

-
- Logística e-commerce**
Amazon, DHL y UPS pilotan camión-drone en zonas suburbanas. Múltiples drones reducen tiempos de entrega hasta un **40%** frente a rutas terrestres puras [10].
-
- Agricultura de precisión**
Drones lanzados desde vehículos terrestres para monitoreo de plagas, riego o entrega de insumos en puntos georreferenciados [12].

-
- Logística humanitaria**
Post-desastre (inundaciones, sismos), la infraestructura vial colapsa. Esquema helicóptero-camión-drone reduce tiempos de respuesta hasta **55%** [11].
-
- Zonas urbanas densas**
Drones eluden el tráfico terrestre. Estudios con datos de Beijing reportan reducción del makespan de **20–30%** frente a reparto exclusivo en camión [13].

Estado del Arte

Enfoque	Método / Referencia	Escala de nodos
Exacto	B&C MILP compacto Dell'Amico et al. 2021 [6]	≤ 39 nodos
Exacto	Branch-and-Price Prog. Dinámica [8]	≤ 12 nodos
Heurística	GRASP + búsqueda local Ha et al. 2018 [4]	100 nodos
Heurística	ALNS (destrucción/repación) Nguyen et al. 2020 [14]	200 nodos
Meta	GA codificación camión-drone Zhou et al. 2024 [16]	100 nodos
Deep L.	Q-learning + metaheurística Chen & Wang 2022 [18]	200+ nodos
LKH-3	Framework unificado Luo et al. 2026 [20]	200+ nodos




Fig. 3: Calidad de solución vs. escala según enfoque

Rol Específico de LKH-3



Fig. 4: Pipeline de LKH-3 para TSP-mD — transformación, búsqueda y factibilización

Arquitectura general

LKH-3 (Helsgaun, 2017) resuelve ~40 variantes de TSP/VRP transformando cada una a un TSP restringido equivalente. Aplica el método k-opt secuencia interna. Los candidatos k-opt actúan sobre la secuencia global sin TSP mD. Ventaja por el árbol generador mínimo. Es de propósito general: no asume estructuras particulares del grafo.

Transformación TSP-mD

Cada operación de drone (i → j → k) se codifica como un nodo virtual en la secuencia global sin TSPMD.tgz. Las restricciones de sincronización y autonomía se implementan como penalizaciones: soluciones infactibles reciben costo alto, guiando la búsqueda hacia regiones factibles.

Benchmarks y resultados

Helsgaun mantiene instancias de referencia TSP-mD en el repositorio cada una a un TSP con candidatos guiados por la medida α (α -nearness), estimada para distinguir movimientos de camión y drone. Las restricciones de sincronización y autonomía se implementan como penalizaciones clave: robustez y generalidad permiten abordar el TSP-mD sin rediseño del solver base. El framework unificado de Luo et al. [20] (2026), basado en LKH- mejorado, supera heurísticas específicas del dominio en instancias medianas.

Conclusiones y Brechas Abiertas

-
- Relevancia creciente:** TSP-mD es motor de la logística de última milla moderna; los UAV reducen makespan hasta un 40% en escenarios favorables.
-
- Complejidad NP-difícil:** reducción desde TSP; métodos exactos limitan a $n \leq 39$. La resolución a gran escala exige heurísticas y metaheurísticas avanzadas.
-
- LKH-3 como referencia:** su transformación a TSP restringido + k-opt guiado lo posiciona como solver generalista competitivo sin rediseño específico.
-
- Brecha 1 — Escala exacta:** formulaciones MILP no superan ~40 nodos. Benders y branch-and-price mejorado son líneas abiertas de investigación.
-
- Brecha 2 — Heterogeneidad:** casi todos los modelos asumen drones homogéneos. Flotas mixtas con distinta autonomía/velocidad son poco exploradas.
-
- Brecha 3 — IA híbrida:** GNN y transformers generan soluciones iniciales prometedoras, pero su integración con LKH-3 como motor de refinamiento está en etapas tempranas.

REFERENCIAS SELECCIONADAS

- [1] Statista, "Last-mile delivery costs," 2023. [2] Macrina et al., Transp. Res. C, 2020. [3] Murray & Chu, Transp. Res. C, 2015. [4] Ha et al., SoICT, ACM, 2018. [5] Helsgaun, Roskilde Univ. Tech. Rep., 2017. [6] Dell'Amico et al., Transp. Res. C, 2021. [7] Garey & Johnson, W.H. Freeman, 1979. [8] Agatz et al., Transp. Science, 2018. [9] Pasha et al., IEEE Trans. ITS, 2022. [10] Arishi et al., Eng. Appl. AI, 2022. [11] Shi et al., Omega, 2024. [12] Nguyen et al., GECCO, 2020. [13] Zhou et al., Transp. Letters, 2024. [14] Chen & Wang, Comput. Ind. Eng., 2022. [15] Luo et al., arXiv:2602.0310, 2026. [16] Thomas et al., Ann. Oper. Res., 2023. [17] Chen & Wang, Comput. Ind. Eng., 2022. [18] Chen & Wang, Comput. Ind. Eng., 2022.

Declaración de uso de IA: Se utilizó Claude (Anthropic) para asistencia en redacción, síntesis bibliográfica y estructuración. Razonamiento crítico y análisis son del equipo. Todas las referencias fueron verificadas por al menos un integrante del grupo.